根号算法——不只是分块

南京外国语学校 王悦同

摘要

根号算法逐渐普及,OI题目的复杂度也变得越来越"多样";不再仅仅是简单的O(N),O(N²),O(NlogN)这种复杂度了。很多题目复杂度里出现了根号,其中数据结构题中的根号算法最为常见,例如分块维护或者"莫队算法"——去年已经有同学详细介绍过了。但是,根号算法绝不仅限于这些地方,它们在很多其它的算法中都会出现,伴随着不同的新奇思想。而对这些思想深入研究,更是能挖掘出比根号更优的复杂度的应用。本文介绍了几种根号算法出现在非数据结构题中的应用,并试图移植这种思想获得更优的算法。

1 算法组合

1.1 从一道水题说起

【例1】Codeforces #80 Div1 D

给出一个长度为N(\leq 300000)的数列a[i],再给出M(\leq 300000)个询问,每个询问是形如(x,y)的形式,你需要输出a[x]+a[x+y]+a[x+2y]+...+a[x+ky]的和,其中x+(k+1)y>N。时限4s。

这题的询问和以往不太一样:大多数同学应该有这样的感觉,我们所学过的大多数数据结构都擅长处理"连续区间"的询问,而不擅长间隔的位置之间的询问。对于本题,线段树之类的传统数据结构难以胜任。但我们发现,假设所有询问的y都一样,那么我们就可以把原序列按下标mod y的值分成y组,询问在对应的组里就是连续的了——而且只需要部分和维护。

这样的问题就是,我们对于v=1要维护若干个数组, size总和为N: 对

于y=2也要,y=3、4、一直到N都需要,难以接受。但我们也不难想到,如果y很大,那么为什么要预存呢?直接暴力不是很快么?每次暴力扫描所有位置是O(N/y)的。因此,取 $K=\sqrt{N}$,我们对于 $1 \le y \le K$ 的情况预存部分和,对于y > K的情况暴力扫描,就可以保证算法的复杂度为 $O(N\sqrt{N})$ 了。

我们回顾一下这题。这题不能完全说不是"数据结构",但它体现的是一种和数据结构题中的根号截然不同的思想。对于题目中的某两个约束,它们是互相制约的,并且这种制约是"乘积"关系——步长和项数,总有一个不能太大。而我们针对两个情况分别设计算法,然后将两种算法组合起来,就能获得一个完整的解决问题的算法。下面看另一道这种思路的简单应用:

【例2】Topcoder SRM589 Level-3 FlippingBits

给一个长度为N(N≤300)的01字符串,再给一个正整数M。每次操作,你可以将一个位置取反,或者将一个长度为M的倍数的前缀取反。问最少需要多少次操作,才能使字符串成为一个循环节为M的循环串。

循环节长度为M定义为,对于任意i,如果i+M这个位置存在,那么i和i+M上的字符应该相等。

本题也不是很难。我们考虑循环节的长度和循环节的个数——这两个乘积(大约)是原串的长度,也就是他们是互相制约的,总有一个不超过 \sqrt{N} 。因此这启示我们分别针对两种情况设计"专杀"算法。首先考虑循环节长度不是很大的情况。这里指的是循环节长度不超过17(也就是300的平方根的近似值)。这个时候我们发现,因为答案要求每一个循环节都一样,而循环节又不长,所以直接枚举: 2^{17} 。枚举出答案以后,每一段必须和答案相等、或者和答案的反串相等。这里很简单,只需要一个动态规划即可,因为注意到记原串每一段是否整体反转,那么操作"将一个长度为M的倍数的前缀取反"的执行次数就是有多少段连续的0和1。

下一种情况就是循环节个数不是很多。这个时候,由于操作"将一个长度为M的倍数的前缀取反"只会在不超过 \sqrt{N} 个位置进行,故仍然可以枚举。这个时候,我们已知每一段是否反转,要构造一个答案来"迎合"它们——这也很简单,对于答案串的每一位,如果所有循环节在这一位的0比较多,这一位就是0;1比较多就是1。因此整个题目就解决了,复杂度为 $O(N*2^{\sqrt{N}})$ 。

我们再来简单回顾这题,和上一题还是比较相似的。通过组合两个"朴素"的算法,得到一个相对高效的做法。更重要的是,这样的"组合算法"解题,几乎是无可替代的——有些题唯一的做法就是通过组合各种算法;或者只有这样才能降低复杂度。这样的做法能扩展到更加复杂的题目上去。

1.2 进一步应用

【例3】IOI2009 Regions

N个节点的树,有R种属性,每个点属于一种属性。有Q次询问,每次询问r1,r2,回答有多少对(e1,e2)满足e1属性是r1,e2属性是r2,e1是e2的祖先。

N,Q≤200000, R≤25000, 时限5s

我初看这题感觉是很正统静态树上的询问(幸好题目要求在线,不然我应该会想的更偏)。不过我想了很久类似O(Nlog²N)之类的算法却毫无进展。后来我看了一眼题解,只看了一点点,立即恍然大悟——题解中告诉我,考虑针对询问的点的个数不同设计不同的算法。

不妨设询问中r1的属性的点有A个,r2属性的点有B个。如果A不大、而B很大呢?我们可以允许扫描A,但是不能扫描B。一种可行的做法如下:考虑dfs序,A中每个节点的子树在dfs序中都对应了一段区间[l,r],而B中每个节点都对应了一个dfs序中的位置p。如果l≤p≤r,那么可以知道A是B的祖先,反之就不是。所以,对于每种属性的节点开一个Vector,将这种属性的所有点的dfs序标号按顺序存进来,那么我们枚举A中的每个点,只要在B对应的vector里二分查找即可。这个算法并不难实现,但是却可以在O(AlogB)的时间内完成一个询问。

那么如果A很大但B不大呢?从直觉来看,我们应该设计一个O(BlogA)的算法。这样的算法确实也是能设计出来的,尽管有点复杂。例如,大概可以这么做:模仿刚刚AlogB的做法,我们扫描B,然后看这个点覆盖了多少区间。因此可以先将该组A个区间全部预处理好,把数组中对应的一段+1,例如有一个区间[5,10],就把数组5至10这一段都+1。这样我们可以直接看这个位置的数而确定这个点被多少区间覆盖了。A个区间端点可以离散化、求和也可以用差分等

方法进行,总之也能在O(BlogA)内完成。

但是我设计出O(BlogA)的做法后发现了更严重的问题。

第一个问题就是,如果询问的A和B都很大,那么无论如何也不可能优于O(A+B)了;A和B都最大可以是N,如果每个询问都这么大,不就直接超时没有优化的余地了么?

但实际上解决这个问题的方案却异常直观。想象一下,一个询问涉及的点数非常多,那么这样的询问不可能有太多;如果有两个询问一样我们必然可以直接查询以前的答案。所以关键就是,同一个询问不做两次。那么不同的询问呢?直接做!复杂度将在后面给出证明。

第二个问题就是,现在即便已经有O(AlogB)和O(BlogA)的做法了,但仍然有这种情况:(假设N和Q是一样的,因为它们是一个数量级),有 \sqrt{N} 种属性,每种有 \sqrt{N} 个,然后N(也就是Q)个询问,把两两属性之间都问了一遍。这个时候不难发现算法复杂度退化到了 $O(N\sqrt{N}logN)$,对于N=200000来说一看就是不可接受的。

通过之前的分析,我们发现,A和B一个很大一个很小的情况是不难办的。但是近似大小的时候呢?我们应该有这样一种感觉,如果我们允许A和B都扫一遍,应该可以设法避免这个log的存在。实际上确实想下去就发现不难了——把A视为区间,B视为点,要求每个点被多少区间包含了,这个实际上可以吧"区间首段点"和点一起做归并,然后顺便维护一个栈就行了,因为A中的区间互不包含,有很多显然的单调性。

最后就是复杂度分析。我们设一个阈值C,对于A>C的情况,使用O(BlogA)的做法,对于B>C的情况使用O(AlogB)的做法,复杂度最坏O(N^2 logN/C);对于其它情况用O(A+B)的做法,复杂度是O(NC)。解出来C= \sqrt{NlogN} 。这里把N和Q混在一起分析了,但他们是一个数量级,所以这么分析没啥问题。整个算法复杂度是O(N \sqrt{NlogN}),可以接受。

刚刚这题就比以往复杂多了;即便是放在当时IOI赛场,也绝非容易。 多种算法的取长补短以保证复杂度的思想,在刚刚那题中得到了很好的体现。

2 另类平衡

2.1 分类维护

"分类维护"是一种数据结构题中的另类思想。同样是根号算法,它和"分块维护"在思想上还是有很大差异的。我们通过一道例题来简要的说明一下这种做法的含义和应用。

【例4】 给出一个N个点M条边的无向图,N,M≤100000。一开始所有的点都是黑色。每次你可以进行两种操作:将一个点反色,或者查询某个点直接连边的点中有多少个黑点。时间限制1s。

本题确实不难,但体现了一种很好的思想。我们发现,在大多数情况下 (随机情况下),直接暴力扫描一个点的出边是很快的。为什么?因为出边少——虽然理论上最坏是O(N)的,但是很难达到。如果一个点出边不多,那么我们就直接询问到的时候枚举即可。

如果出边很多咋办呢?我们应该有这样的反应——一个多,另一个就少;出边多,这样的点就少。我们不妨以 \sqrt{N} 为界来讨论(一般都可以以 \sqrt{N} 为界讨论,等到最后卡复杂度的时候再仔细估算阈值大小)。如果一个点度数 $<\sqrt{N}$,那么直接维护,复杂度是 $O(M\sqrt{N})$;如果度数大了,则这样的点最多 \sqrt{N} 个,我们可以直接每次修改后都暴力维护一遍这些点的答案——很简单,一旦修改,就扫描这 \sqrt{N} 个点,看看这次修改和它是否有关。这个也显然能在 $O(\sqrt{N})$ 时间内维护。因此本题通过组合这两种情况的维护方法,就可以实现 $O(N\sqrt{N})$ 的复杂度。

2.2 轻松一刻

下面我们来看一个很简单有趣的题目放松一下。

【例5】烧桥计划(JSOI2013互测)

给一个长度为N的数列(N \leq 100000) $A_1,A_2...A_n$ (1000 \leq A_i \leq 2000)。 你需要从中选出若干个数(个数不限,也可以不选),记为K 个,分别为 $A_{p_1},A_{p_2}...A_{p_K}$ (p数列严格递增)。 这次选数的代价是 A_{p_1} *1+ A_{p_2} *2+...+ A_{p_K} *K。

这些选出来的数把剩下的N-K个数分成了K+1 段(可能有空段)。记每一段中A数列的和为 T_i ,对于所有 T_i >M的段,产生额外的 T_i 的代价,否则没有任何额

外代价。对所有的 T_i ,M都是一样的,输入的数 $\leq 2*10^8$ 。求一种选数方案,使得总代价最小。时限7s。

我们不难设计出一个二维的状态f[i][j],表示当前最后一个选择的位置是i,且这个位置是从左到右第j个选择的位置,此时j个位置和j段数生成的总代价,最少是多少。因此可以写出状态转移方程:记sum[i]表示前i个A数组的和,

 $F[i][j]=min(F[k][j-1]+(A_i)*j)$ for $sum[i-1]-sum[k] \leq M$

 $F[i][j]=min(F[k][j-1]+(A_i)*j+sum[i-1]-sum[k])$ for sum[i-1]-sum[k]>M 其中 $0 \le k < i$

对这个动态规划稍加分析,就可以发现利用单调队列可以将复杂度降到 $O(N^2)$ ——剥离变量后直接维护,因为比较显然,所以这里不详细说明了。关键是原题是N=100000,这个做法仍然太慢。哪儿还能优化呢?

这题是我在JSOI2013的省队互测中出的一道"搞笑"题,现场没有人做出来;其实不是难题,而是没有反应过来"脑筋急转弯"。原题中有一个条件, $1000 \le A_i \le 2000$ 。上界正常,下界有什么用呢?注意到题目中选一个 A_i 的代价其实是越来越大的,所以我们不能选太多!

对于一个数都不选的情况,总代价 \leqslant 2000*N(只有一段) 对于选了i个数的情况,总代价 \geqslant i*(i+1)/2*1000 \geqslant 500*i*i 要使得选i个数时答案可能成为最优解,必须有500*i*i \leqslant 2000*N 即i \leqslant \sqrt{N} *2

因此状态个数是 $O(N\sqrt{N})$ 的,即可通过本题了。

我把这题放在这儿也并非和其它题没有关联;毕竟,它也是一个 $O(N\sqrt{N})$ 的算法,根号的来源也同样奇特——来源于对题目中下界的分析。我当时出这题时受到topcoder某道题的启发:那题是说,给出K个点分成N层,相邻层之间有些点有边,第一层和最后一层也有一些边。求这个图的最大独立集。K \leq 100,10 \leq N \leq 100。这题中"最大独立集"明显是需要利用二分图的性质进行匹配,但如果N是奇数则不是二分图,怎么办?注意到题目中N不小于10,而点数不多于100,所以一定有一层点数不超过10。我们枚举这一层的所有情况,就可以"破环为链"了。这题和主题关系不大,但还是顺便介绍一下;毕竟如果上界和下界可以视为一个数量级(差小常数倍,例如原题差2倍),则经常可以通过上下界的分析得到和根号有关的性质,作为解题的突破口。我们再回到原主题:

2.3 内存优化

也许卡内存的情况在OI中并不常见。但既然时间可以有这样的优化,内存为何不可以呢?通过类比的扩展,内存也可以得到类似的优化,而且幅度并不小——所以其实也是一种很有用的思路。我们通过一道题目来看一下这种应用。

【例6】Codeforces #79 Div1 E

你现在有N(≤20000)颗石子和M(≤20000)颗糖果,准备把它们吃完。现在有N个参数A[i]和M个参数B[j],每次你可以选择吃一个糖果或者一个石子,吃完之后,如果剩下来x颗石子和y颗糖果,你就可以得到(A[x]+B[y])mod P的奖励(P也是给定的),然后你继续吃。你要最大化M+N次得到的所有奖励之和。你需要输出方案:每次是吃糖果还是石子。时间限制15s,内存限制45MB。

如果不考虑内存限制的问题,这题还是很容易的。一个动态规划: F[i][j]表示吃了i个糖果、j个石子时的最优答案。F[i][j]=(A[N-i]+B[M-j])mod P+max(F[i-1][j],F[i][j-1])。这应该大家都会; 至于记录方案,只要另一个数组G记录每个位置从哪儿转移来的就行了。

那么回来看内存限制呢? 大家应该都能想到F数组可以滚动数组、而G可以压位。不过算了一下发现这样也需要五十多兆内存……所以考虑另辟蹊径。

直接存下这个表内存是不够的。但我们为啥要全部存下来呢?例如,我们如果记录了倒数第K行的答案,那么从第K+1行到第N行的空间就可以和前面"公用",因为我把这段的答案得出来后直接输出,以后就规约为从第K行往前的答案的问题了。受此启发,我们考虑适当存一些行的答案,以尽可能公用空间。

想到这里就不难想到根号了; 凭直觉来也应该是每 \sqrt{N} 行存一次答案(也就是F数组,这里不滚动了)。这样我们只需要 $O(N\sqrt{N})$ 的空间存储这些信息,就可以分段恢复答案了! 我们要f[M][N]的答案,但我们既然有了 $M-\sqrt{N}$ 这一行的答案,就可以从这一行开始dp,然后得出这一段的"最优路径"; 然后同样的空间还可以恢复上面 \sqrt{N} 行的答案,再往上,以此类推。这是一种另类的平衡。虽然理解起来不困难,但思维还是很新奇的,是根号思想的一种扩展应用。整个算法复杂度仍然是 $O(N^2)$,但空间是 $O(N\sqrt{N})$ 了。

3 自然出现

也有一些时候,我们并不是刻意去让根号出现在算法里,但是它却会无意中就出现了。举个例子: N div i(整除)当i取遍1至N时,只有O(\sqrt{N})种不同的取值。这个并不难证明: 当i $<\sqrt{N}$ 时,最多也就 \sqrt{N} 个不同的答案; 而当i $>\sqrt{N}$ 时,答案落在[1, \sqrt{N}]的区间内,也最多 \sqrt{N} 个。这个性质有一些应用;下一个例子介绍了一下这一类"自然出现"的 \sqrt{N} 如何应用起来。

【例7】POI2007 Queries

有N(\leq 50000)组询问,对于给定的整数a,b和d,有多少正整数对x,y,满足x \leq a,y \leq b,并且gcd(x,y)=d。

本题是一个数学类问题。首先分析一下题目,gcd(x,y)=d这个可以直接转化为gcd(x,y)=1,并且把a和b的范围同时缩小为a/d和b/d。也就是说,我们要求出有多少互质的数对,一个不超过a,一个不超过b。这和NOI2010的能量采集十分像,可以直接通过容斥原理解决。具体做法就是,设F(x)表示有多少对数,一个不超过a,一个不超过b,并且它们的gcd 是x的倍数。这很简单——F(x)=(a div x)*(b div x)。接下来用容斥即可,答案=F(1)-F(2)-F(3)-F(5)+F(6)-F(7)······,其中F(x)加到答案中前面有一个系数p(x),如果x中某种质因子含有超过一个,则p(x)=0,否则 $p(x)=(-1)^G$,其中G表示x中不同质因子的个数。直接这么做是每个询问O(N)的,相比 $O(N^2)$ 的暴力确实好得多,但仍然复杂度不满足要求。

我们观察式子,发现我们要做的其实就是,尽快求出 $\sum F(i)*p(i)$ 。p(i)规律并不明显,但F(i)呢?之前我们说过,N div i的取值个数是 $O(\sqrt{N})$ 级别的,那么F(x)和它有直接的关联——a div x和b div x都只有 $O(\sqrt{N})$ 级别的不同取值,所以F(x)取值也是同一个数量级的!

对于连续一段相邻的F(x),如果他们相等,就可以一并计算。这里仅仅需要维护一个p(x)数组的部分和就行了。通过维护p(x)的部分和和将相同的F(x)一起计算,我们成功的做到了在 $O(\sqrt{N})$ 的时间内回答一次询问,因此可以通过本题。

本题中所说的p(x)这个函数还有一个名字叫"Mobius函数",去年集训队王迪同学的论文里讲到过。这里并没有深入挖掘它在数学上的更多性质和广泛应用,只是以此为例,指出了一类利用"自然"存在的性质对算法进行优化的思路。

参考文献

- [1] 《21-st International Olympiad In Informatics TASKS AND SOLUTIONS》 from www.ioi2009.org
- [2] 《POI.XIV.sol》2008国家集训队作业,成都七中-周梦宇
- [3] 《浅谈容斥原理》2013国家集训队论文,成都七中-王迪